




Aplicaciones de aprendizaje automático en energía eólica

Daniel Cabezón
Departamento de Evaluación energética EDPR

Barcelona, 29 de Mayo de 2019

INDEX



- A PUNTOS CLAVE
- B EDP RENOVAVEIS
- C APLICACIONES DE APRENDIZAJE AUTOMÁTICO
- D CONCLUSIONES
- E RECOMENDACIONES Y NUEVOS RETOS

A photograph of a wind turbine in a cornfield at sunset. The sky is a mix of blue and orange, with wispy clouds. The foreground is filled with the golden-brown stalks of corn. A dark, semi-transparent horizontal band runs across the middle of the image, serving as a background for the text.

PUNTOS CLAVE




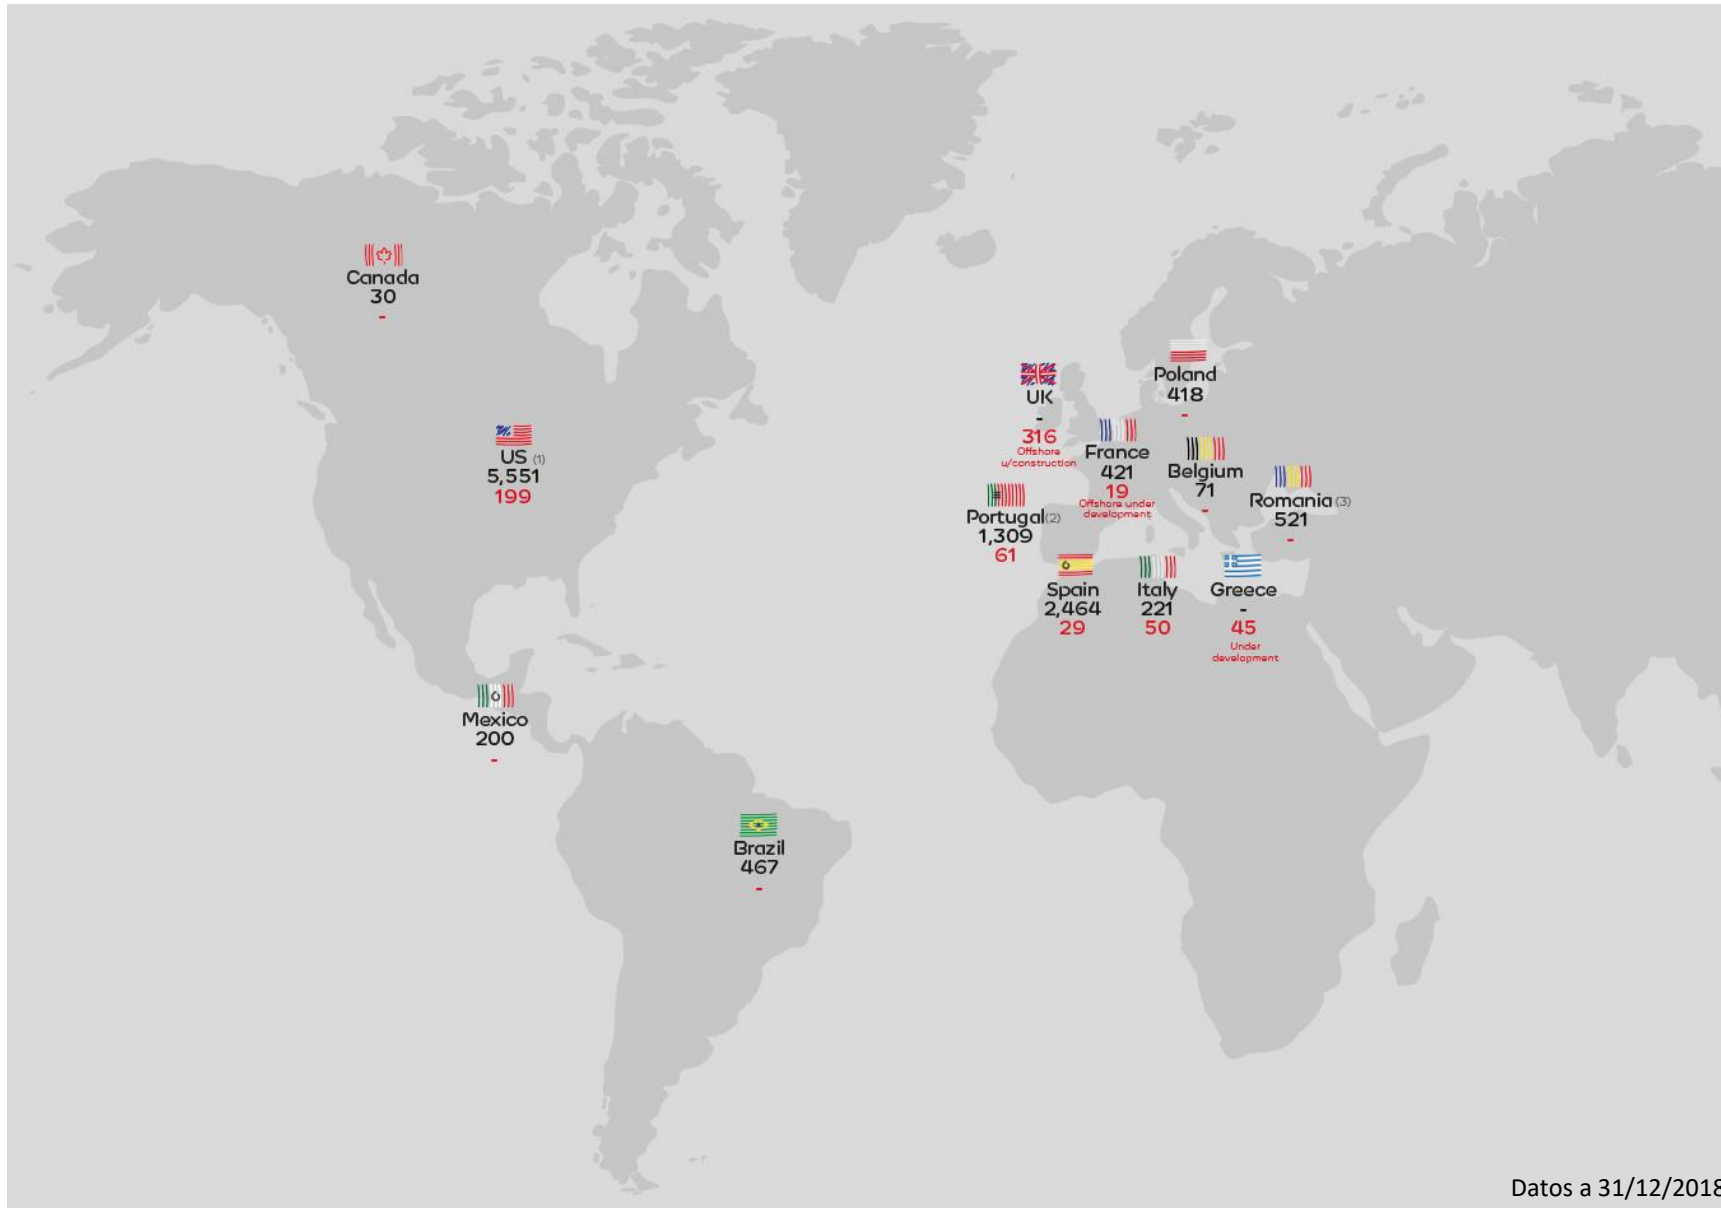
PUNTOS CLAVE

- Minimizar costes de desvío en la predicción de producción
- Identificar emplazamientos críticos en climas fríos
- Proteger las turbinas ante vientos extremos de tormenta

A wide-angle photograph of a solar farm in a desert. In the foreground, rows of solar panels are visible, angled towards the sun. The panels are mounted on metal frames. In the middle ground, there's a small, light-colored building. The background features a range of rugged mountains under a clear sky. The lighting suggests it's either early morning or late afternoon, with a warm, golden glow. The text "EDP RENOVAVEIS" is overlaid in the center of the image.

EDP RENOVAVEIS

EDPR está presente en 14 países, con un portfolio de 12 GW – 4º operador mundial



A photograph of an offshore wind farm with several white wind turbines in a row over the ocean under a clear blue sky. A semi-transparent dark grey horizontal band is overlaid across the middle of the image, containing the title text.

APLICACIONES DE APRENDIZAJE AUTOMÁTICO

APLICACIONES DE APRENDIZAJE AUTOMÁTICO

1

Predicción de la
producción para el
día siguiente

2

Estimación de
pérdidas de energía
por hielo en palas

3

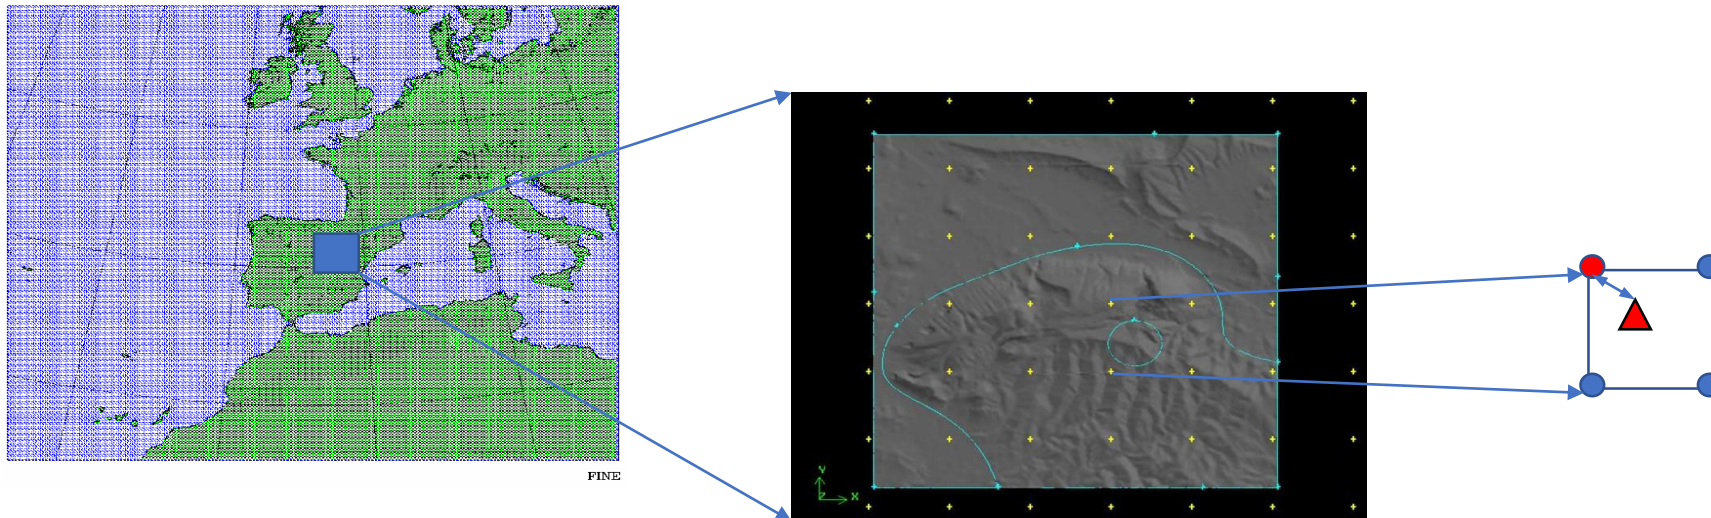
Caracterización de
vientos extremos de
tormenta

1. Predicción de la producción de parques eólicos


Objetivo: estimar la energía a inyectar a la red durante el día siguiente (0h – 23h), minimizando el error de predicción

Problema: los modelos meteorológicos tienen una resolución limitada y solo ofrecen predicción de viento en nodos discretos de una malla

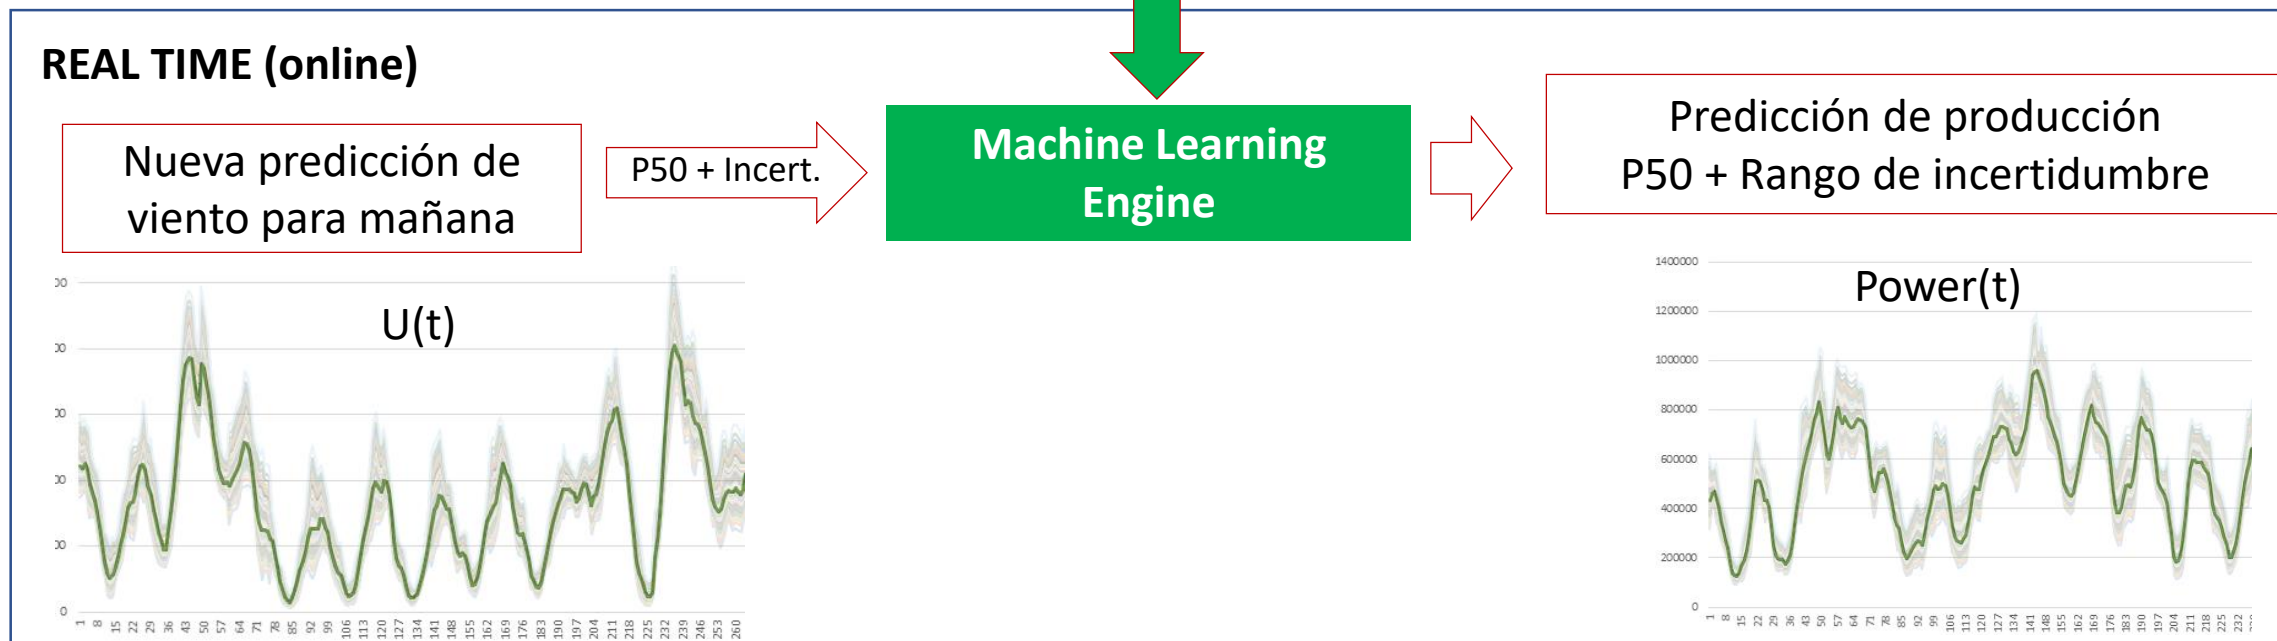

Solución: aplicamos algoritmos de Aprendizaje Automático para relacionar predicciones históricas de viento (o más variables) con la producción real que realmente se registró



1. Predicción de producción de parques eólicos




Nodo más cercano



1. Predicción de producción de parques eólicos

Computación periódica (semanal / mensual) de desvíos

Métricas de error: MAE (error medio absoluto) y BIAS (error sistemático)



2. Estimación de pérdidas por hielo en palas

Objetivo: Estimar las pérdidas de energía anuales por hielo en palas en plantas ubicadas en climas fríos

Problema: la acreción de hielo en palas es variable y depende de factores ambientales y operacionales de las turbinas


Solución: aplicamos algoritmos de Aprendizaje Automático para predecir eventos de hielo en turbinas a partir de variables meteorológicas y eventos de hielo registrados en los SCADA de las turbinas



2. Estimación de pérdidas por hielo en palas

Variables predictoras

Temperatura del aire
Humedad relativa
Diferencia temporal de temperaturas
Hora del día
Día del año




Variable respuesta


Evento de hielo en rotor (0 / 1)

Modelos de aprendizaje automático: Classification Support Vector Machine + Decision trees

2. Estimación de pérdidas por hielo en palas



2. Estimación de pérdidas por hielo en palas



Hielo instrumental (% horas mensuales) en 2 inviernos

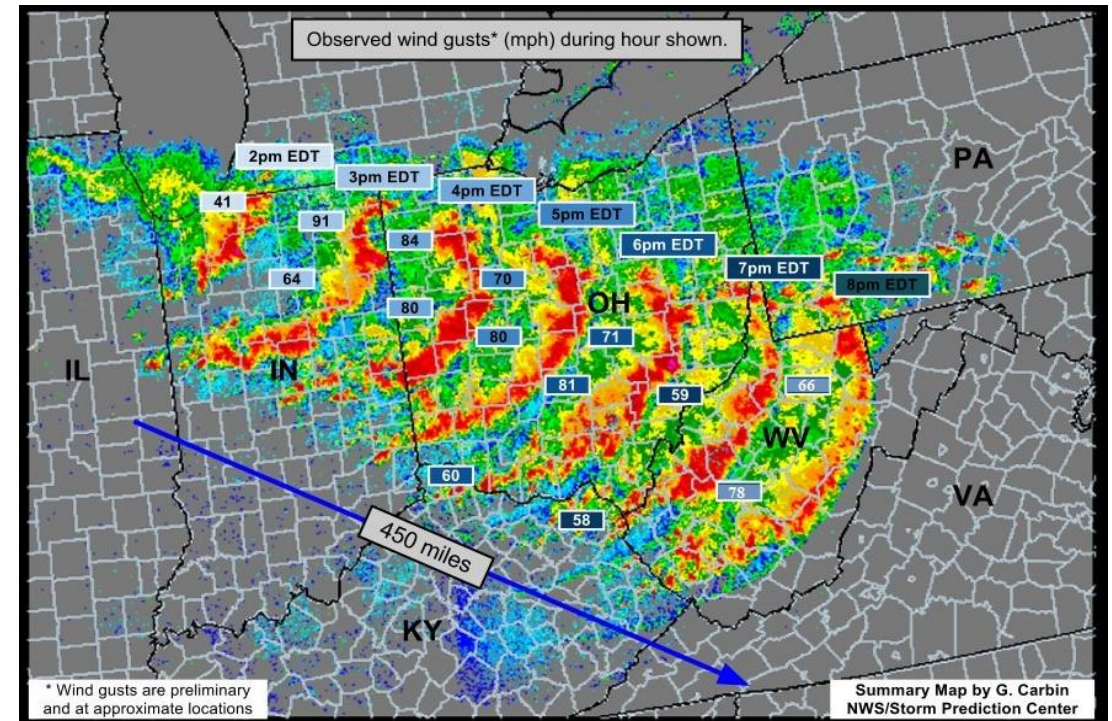
3. Identificación de eventos de tormenta

Objetivo: identificar histórico de tormentas convectivas y viento máximo esperado para diseño de turbinas

Problema: escalas espacial y temporal reducidas -> eventos difíciles de registrar completamente

Solución: aplicamos algoritmos de Aprendizaje Automático para identificar eventos de tormenta a partir de variables meteorológicas registradas en estaciones de medida

G. Carbin, NWS SPC (2012)



3. Identificación de eventos de tormenta

Red pública de estaciones de medida ASOS (automated surface observing stations)

La mayor parte en aeropuertos con mejor exposición

Entre otras variables, las estaciones ASOS registran eventos de tormentas convectivas



Fig. 1. Locations of approximately 1200 ASOS stations suitable for analysis.

3. Identificación de eventos de tormenta


Variables predictoras

Variables meteorológicas en nodos adyacentes
indicadores de tormenta convectiva

- Perfil vertical de viento
- Radiación de suelo
- CAPE (convective available potential energy)
- CIN (convective inhibition)

Variable respuesta

Evento de tormenta registrado en estaciones ASOS
cercanas (día-hora y valor máximo de velocidad)



CONCLUSIONES



Modelos de aprendizaje automático implementados en MATLAB nos permiten encontrar patrones y relaciones entre **variables meteorológicas y medidas registradas** en turbina, con las siguientes implicaciones:

- Reducir considerablemente costes de desvío (predicción)
- Realizar estimaciones realistas de pérdidas anuales por hielo en palas en nuevos emplazamientos ubicados en climas fríos
- Instalar de forma segura turbinas en emplazamientos con tendencia a tormentas fuertes

NUEVOS RETOS

Integración en Sistema de Big Data

- Medidas de alta frecuencia de 250 parques eólicos - 7100 turbinas
- Filtros de calidad
- Algoritmos de aprendizaje automático

CONTACTS



Daniel Cabezón

daniel.cabazon@edpr.com



edp renováveis

Energy Assessment

www.edpr.com